

# Capítulo 1

## Distribuição Amostral

### 1.1 Introdução

O conhecimento das distribuições amostrais é fundamental para a aplicação de técnicas de inferências estatísticas. Inferência é o processo de obter informações sobre uma população a partir de uma amostra.

Sendo uma população com  $N$  elementos, da qual se deseja retirar todas as amostras possíveis de tamanho  $n$ , ou seja, podem ser obtidas  $N^n$  amostras ( no caso de retiradas com reposição) ou  $C_{N,n}$  amostras ( no caso de retiradas sem reposição). Em cada amostra pode-se calcular o valor de um certo estimador  $\hat{\theta}$  ( $\bar{X}$ ,  $S^2$ , *etc.*); o conjunto de valores das estimativas de  $\hat{\theta}$ , forma uma distribuição de probabilidades denominada distribuição amostral (ou por amostragem) de  $\hat{\theta}$ .

Seja  $X$  uma variável populacional que se deseja estudar. Uma amostra aleatória de  $X$  é o conjunto de  $n$  variáveis aleatórias independentes ( $X_1, X_2, \dots, X_n$ ) tal que cada  $X_i$ ,  $i = 1, 2, \dots, n$  tem a mesma distribuição da variável  $X$ . Se a população for infinita, os valores da amostra aleatória também serão igualmente distribuídos pois, neste caso, a retirada de alguns elementos não modificará a distribuição de probabilidade da população.

Para formalizar as idéias que serão apresentadas neste capítulo precisamos definir alguns conceitos que seguem abaixo.

### 1.1.1 Parâmetros, Estimativas e Estimadores

**Def.:** Parâmetro é a quantidade da população, em geral desconhecida, que temos interesse. Usualmente representadas pelas letras gregas como  $\theta, \mu, \sigma$ , entre outras.

**Def.:** Estimador é a combinação dos elementos da amostra construída com a finalidade de estimar um parâmetro de interesse da população. Em geral, denotada por  $\hat{\theta}, \hat{\mu}, \hat{\sigma}$ , entre outras.

**Def.:** Estimativas são os valores numéricos assumidos pelos estimadores.

Notamos que um estimador, digamos  $\hat{\theta}$ , é uma função das variáveis aleatórias da amostra, isto é,  $\hat{\theta} = f(X_1, X_2, \dots, X_n)$ . Logo, um estimador também é uma variável aleatória.

O problema da estimação é, então, determinar uma função  $\hat{\theta} = f(X_1, X_2, \dots, X_n)$  que seja próxima de  $\theta$ , segundo algum critério. Tais critérios (propriedade) são apresentados a seguir.

**Prop.1  $\Rightarrow$  Vício:** Um estimador  $\hat{\theta}$  é não viciado ou não viesado para um parâmetro  $\theta$  se  $E(\hat{\theta}) = \theta$ .

**Prop.2  $\Rightarrow$  Consistência:** Um estimador  $\hat{\theta}$  é consistente se, à medida que o tamanho da amostra aumenta, seu valor esperado converge para o parâmetro de interesse e sua variância converge para zero. Ou seja,

$$i) \lim_{n \rightarrow \infty} E(\hat{\theta}) = \theta \quad ii) \lim_{n \rightarrow \infty} Var(\hat{\theta}) = 0.$$

Quando dois estimadores forem consistentes e não viciados para um mesmo parâmetro precisamos de definir qual é mais preciso. Neste caso, temos o conceito de eficiência do estimador, como segue.

**Prop.3  $\Rightarrow$  Eficiência:** Dado dois estimadores  $\hat{\theta}_1$  e  $\hat{\theta}_2$ , não viciados para um parâmetro  $\theta$ , dizemos que  $\hat{\theta}_1$  é mais eficiente do que  $\hat{\theta}_2$  se  $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$ .

**Exemplo:** No caso de Distribuição Normal, verifica-se que os estimadores  $\hat{\mu}_1 = \bar{X}$  e  $\hat{\mu}_2 = \text{mediana}(X_1, \dots, X_n)$  são não viciados e suas variâncias são

$$\text{Var}(\hat{\mu}_1) = \frac{\sigma^2}{n} \quad \text{e} \quad \text{Var}(\hat{\mu}_2) = \frac{(\pi/2)\sigma^2}{n}.$$

Então,

$$\frac{\text{Var}(\hat{\mu}_1)}{\text{Var}(\hat{\mu}_2)} = \frac{\sigma^2/n}{(\pi/2)\sigma^2/n} = \frac{2}{\pi} = 0,63 < 1 \Rightarrow \text{Var}(\hat{\mu}_1) < \text{Var}(\hat{\mu}_2),$$

concluimos que  $\hat{\mu}_1$  é mais eficiente do que  $\hat{\mu}_2$ .

## 1.2 Distribuição Amostral da Média $\bar{X}$

Seja  $(X_1, X_2, \dots, X_n)$  uma amostra aleatória extraída de uma população  $X$  com média  $\mu$  e variância  $\sigma^2$ . Sabe-se que  $\bar{X} = (\sum_{i=1}^n x_i)/n$  representa a média amostral. Como a amostra é aleatória, cada  $X_i$  tem a mesma distribuição da população, ou seja,

$$E(X_i) = \mu \quad \text{e} \quad \text{Var}(X_i) = \sigma^2, \quad i = 1, 2, \dots, n.$$

Como a amostra foi extraída ao acaso,  $X_1, X_2, \dots, X_n$  são independentes. Então,

$$E(\bar{X}) = E\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} \sum_{i=1}^n \mu = \frac{n\mu}{n} = \mu.$$

Portanto,  $E(\bar{X}) = \mu \rightarrow$  é um estimador justo de  $\mu$ .

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

Portanto,  $\text{Var}(\bar{X}) = \frac{\sigma^2}{n} \rightarrow$  é consistente, pois  $\text{Var}(\bar{X}) \rightarrow 0, n \rightarrow \infty$ .

$$\text{Assim, se } X \stackrel{d}{=} N(\mu, \sigma^2) \Rightarrow \bar{X} \stackrel{d}{=} N\left(\mu, \frac{\sigma^2}{n}\right).$$

Então, se a distribuição da população for normal, a distribuição amostral de  $\bar{X}$  também será normal, para qualquer tamanho da amostra.

No caso de amostragem sem reposição de população finita, pode-se demonstrar que:


$$X \stackrel{d}{=} N(\mu, \sigma^2) \Rightarrow \bar{X} \stackrel{d}{=} N\left[\mu, \frac{\sigma^2}{n} \left(\frac{N-n}{N-1}\right)\right],$$

onde a fração  $\left(\frac{N-n}{N-1}\right)$  é chamada fator de correção da população finita.

Se a distribuição da população não for normal, mas a amostra for suficientemente grande, resultará do Teorema do Limite Central que a distribuição amostral de  $\bar{X}$  será aproximadamente normal no caso de população infinita ou amostragem com reposição.

**O Teorema do Limite Central** garante que *"sob condições bastante gerais, uma variável aleatória, resultante de uma soma de  $n$  variáveis aleatórias independentes, tem distribuição normal, no limite para  $n$  tendendo a infinito"*.

Na figura abaixo tem-se uma distribuição populacional não-normal e a correspondente distribuição amostral de  $\bar{X}$ , para um  $n$  suficientemente grande.



**Exemplo:** Seja  $X$  uma população constituída dos seguintes elementos 2, 3, 4, 5. Extrair todas as amostras de 2 elementos dessa população, com reposição, e determinar:

- Média e variância da população.
- Média e variância da distribuição das médias.

**Solução:** Temos que:

$$a) \mu(X) = \frac{2+3+4+5}{4} = 3,5.$$

$$\sigma^2(X) = \frac{(2-3,5)^2 + (3-3,5)^2 + (4-3,5)^2 + (5-3,5)^2}{4} = 1,25.$$

$$b) E(\bar{X}) = \mu = 3,5; \quad Var(\bar{X}) = \frac{\sigma^2(X)}{n} = \frac{1,25}{2} = 0,625.$$

Podemos verificar a validade dos resultados obtidos. Para isso, listar todas as amostras de tamanho 2, com reposição; a seguir calcular a média de cada amostra e, em seguida, calcular a média e variância das médias amostrais.

Assim, teremos:

$$\begin{aligned} \text{Amostras} = \{ & (2,2), (2,3), (2,4), (2,5), (3,2), (3,3), (3,4), (3,5), \\ & (4,2), (4,3), (4,4), (4,5), (5,2), (5,3), (5,4), (5,5), (5,6) \} \end{aligned}$$

$$\text{Médias Amostrais} = \{2; 2,5; 3; 3,5; 2,5; 3; 3,5; 4; 3; 3,5; 4; 4,5; 3,5; 4; 4,5; 5\}$$

$$\text{Com reposição} \Rightarrow N^n = (4)^2 = 16.$$

$$E(\bar{X}) = \frac{2+2,5+\dots+5}{16} = 3,5$$

$$Var(\bar{X}) = \frac{(2-3,5)^2+\dots+(5-3,5)^2}{16} = \frac{10}{16} = 0,625.$$

Podemos desenvolver o item (b) supondo agora amostragem sem reposição:

$$E(\bar{X}) = \mu = 3,5; \quad Var(\bar{X}) = \frac{\sigma^2(X)}{n} \left( \frac{N-n}{N-1} \right) = \frac{1,25}{2} \left( \frac{4-2}{4-1} \right) = 0,417.$$

ou, considerando  $C_{N,n} = C_{4,2} = 6$

$$\text{Amostras} = \{(2,3), (2,4), (2,5), (3,4), (3,5), (4,5)\}$$

$$\text{Médias Amostrais} = \{2,5; 3; 3,5; 3,5; 4; 4,5\}$$

$$E(\bar{X}) = \frac{2,5+3+\dots+4,5}{6} = 3,5 \quad e \quad Var(\bar{X}) = \frac{(2,5-3,5)^2+\dots+(5-3,5)^2}{6} = 0,417.$$

## 1.3 Distribuição Amostrai da Frequência Relativa

Seja  $X$  uma população infinita,  $p$  a probabilidade de sucesso de certo evento e  $q = 1 - p$  a probabilidade de insucesso.

Seja  $(x_1, x_2, \dots, x_n)$  uma amostra aleatória de  $n$  elementos dessa população e  $x$  o número de sucessos na amostra. Então, temos uma variável com distribuição Binomial com média  $(np)$  e variância  $(npq)$ . Assim, a distribuição amostral da frequência relativa (proporção)  $f = \frac{x}{n}$  será dada por:

$$E(f) = E\left(\frac{x}{n}\right) = \frac{np}{n} = p \quad e \quad Var(f) = Var\left(\frac{x}{n}\right) = \frac{1}{n^2} npq = \frac{pq}{n}.$$

Para  $n \geq 30$  a distribuição amostral de  $f$  será normal

$$f \stackrel{d}{=} N\left(p, \frac{pq}{n}\right).$$

Assim, a distribuição padronizada será

$$Z_i = \frac{f_i - p}{\sqrt{\frac{pq}{n}}}.$$

## 1.4 Distribuição Amostral de Variâncias $S^2$

Sabemos que a variância populacional é designada por  $\sigma^2$ . Então, a variância amostral  $S^2$  é o estimador de  $\sigma^2$ . Assim,  $S^2$  tem distribuição qui-quadrado ( $\chi^2$ ) com  $(n-1)$  graus de liberdade (ouseja, a soma de  $(n-1)$  variáveis normais padronizadas e independentes) dada por:

$$\frac{(n-1)S^2}{\sigma^2} \stackrel{d}{=} \chi_{(n-1)}^2.$$

Aqui  $(n-1)$  e  $\sigma^2$  são constantes.

Os parâmetros da distribuição amostral de  $S^2$  são:

$$E(S^2) = \sigma^2 \quad \text{e} \quad Var(S^2) = \frac{2\sigma^4}{(n-1)}.$$

## 1.5 Distribuição Amostral da Soma ou Diferença de Duas Médias

Queremos obter a distribuição amostral do estimador  $(\bar{X}_1 \pm \bar{X}_2)$ .

Sabemos que:  $\bar{X}_1 \stackrel{d}{=} N\left(\mu_1, \frac{\sigma_1^2}{n_1}\right)$  e  $\bar{X}_2 \stackrel{d}{=} N\left(\mu_2, \frac{\sigma_2^2}{n_2}\right)$ .

Considerando-se as amostras independentes de duas populações tem-se:

$$(\bar{X}_1 \pm \bar{X}_2) \stackrel{d}{=} N\left(\mu_1 \pm \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right).$$

## 1.6 Distribuição amostral da Soma ou Diferença de duas Frequências

Se  $f_1 \stackrel{d}{=} N(p_1, \frac{p_1 q_1}{n_1})$  e  $f_2 \stackrel{d}{=} N(p_2, \frac{p_2 q_2}{n_2})$  são válidas quando  $n \geq 30$ , então a distribuição amostral das diferenças ou somas será aproximadamente normal com:

$$(f_1 \pm f_2) \stackrel{d}{=} N(p_1 \pm p_2, \frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}).$$

## 1.7 Exercícios

1- Uma população consiste de cinco números: 2, 3, 6, 8, 11. Consideremos todas as amostras possíveis de 2 elementos que dela podemos retirar, com reposição. Determinar:

- a) a média e o desvio padrão da população;
- b) a média e o desvio padrão da distribuição amostral das médias.

2- Resolver o problema anterior, no caso da amostragem sem reposição.

3- Admitindo-se que o comprimento das peças produzidas por uma máquina (produção de 3.000 peças) é normalmente distribuída com uma média de 172,72 mm e desvio padrão de 7,62 mm, e obtendo-se 80 amostras, de 25 peças cada uma, quais serão a média e o desvio padrão esperados da distribuição amostral das médias, supondo que a amostragem é feita:

- a) com reposição;                      b) sem reposição.

4- Em quantas amostras do problema anterior pode-se esperar que a média se encontre:

- a) entre 169,67 mm e 173,48 mm;                      b) abaixo de 169,65 mm.

5- Certos amortecedores fabricados por uma empresa têm uma vida média de 800 dias e desvio padrão de 60 dias. Determinar a probabilidade de uma amostra aleatória de 16 amortecedores, retirados do grupo, ter a vida média:

- a) entre 770 e 830 dias;                      c) superior a 820 dias;

b) menor que 785 dias;                      d) entre 790 e 810 dias.

6- Os pesos dos pacotes recebidos por um depósito têm uma média de 150 kg e um desvio padrão de 25 kg. Qual é a probabilidade de 25 pacotes, retirados ao acaso e carregados em, um elevador, não excederem o limite de segurança deste, que é de 4.100 kg?

7- Determinar a probabilidade de, em 120 lances de uma moeda honesta, ocorrerem caras:

a) entre 40 e 60%;                      b) em  $5/8$  ou mais.

8- Uma pesquisa de opinião pública numa comunidade mostrou que 46% das pessoas são favoráveis a um projeto de lei. Determinar a probabilidade de que a maioria das pessoas, de um conjunto amostral de 1.000 pessoas, seja favorável a tal projeto.

9- Entre 1.000 amostras, de 200 crianças cada uma, em quantas espera-se encontrar:

a) menos de 40% de meninos;  
b) 53% ou mais de meninas.

10- Seja  $X_1$  uma variável que representa qualquer dos elementos da população: 3, 7, 8.

E  $X_2$  que representa qualquer dos elementos da população: 2 e 4. Calcular:

a)  $E(X_1)$  e  $Var(X_1)$ ;  
b)  $E(X_2)$  e  $Var(X_2)$ ;  
c)  $E(X_1 - X_2)$  e  $Var(X_1 - X_2)$ .

### Respostas:

1- a)  $\mu = 6,0$ ;  $\sigma = 3,29$     b)  $E(\bar{X}) = 6,0$ ;  $S(\bar{X}) = 2,32$ .

2- a)  $\mu = 6,0$ ;  $\sigma = 3,29$     b)  $E(\bar{X}) = 6,0$ ;  $S(\bar{X}) = 2,01$ .

3- a)  $E(\bar{X}) = 172,72$ ;  $S(\bar{X}) = 1,524$     b)  $E(\bar{X}) = 172,72$ ;  $S(\bar{X}) = 1,518$ .

4- a) 54                      b) 2.

5- a) 95,44%    b) 15,87%    c) 9,18%    d) 49,72%.

6- 99,74%.



7- a) 97,08%    b) 0,32%.

8- 0,62%.

9- a) 2    b) 200

10- a)  $\mu(X_1) = 6$ ;  $\sigma(X_1) = 2,16$

b)  $\mu(X_2) = 3$ ;  $\sigma(X_2) = 1$

c)  $\mu(X_1 - X_2) = 3$ ;  $\sigma(X_1 - X_2) = 2,38$ .